

Project Proposal

面向真实业务库的 Text2SQL：one-shot 与 Agent 闭环的对照研究

《数据库前沿技术》期末考核 A 卷 | 方向 4 (AI4DB: Text2SQL / Database Agent) | 数据: BIRD Mini-Dev V1 (SQLite) | 模型: deepseek-flash

一、问题 (Problem)

在真实业务库上把自然语言问题自动翻译成结果正确的 SQL。BIRD Mini-Dev 的题目横跨赛事统计 (formula_1)、医疗检验 (thrombosis_prediction)、金融卡业务 (debit_card_specializing) 等库, 需要多表连接、聚合、子查询与业务口径理解。

已有方案的局限. 规则/模板只能覆盖固定问法; 传统 Seq2Seq 依赖大规模标注语料, 且生成时看不到执行结果, 无法自我纠错; 单次 LLM 调用 (one-shot) 能跑通, 却有系统性错误模式——模型语义方向多数正确, 输出形态却多带佐证列, 而官方判分是结果集集合比较, 多一列即整题判错。故主要瓶颈不在”推理能力”, 而在输出形态与表选择。

研究问题. RQ1: 带执行反馈的 agent 闭环能否显著提升 EX? RQ2: 增益来自”多轮”这一结构本身, 亦或是某个具体机制? RQ3: 用独立采样 + 结果集投票替代迭代反馈是否合理?

二、数据 (Data)

数据集	BIRD Mini-Dev V1, SQLite 版 (官方公开评测集, 自带 gold SQL)
规模	500 题 / 11 库 / 75 表 / 1618 列; 难度分布 simple 148、moderate 250、challenging 102
题目字段	question_id、db_id、question、evidence (2 条缺失)、SQL (gold)、difficulty
库侧	沿用分发的 11 个 .sqlite: 不改 DDL、不建索引, 只读 mode=ro (card_games 为 WAL, 回退 immutable=1)
划分	全量 500 题即评测集, 不另设训练集 (零训练; 数据只进 prompt 上下文与判分)

数据集本身即评测口径: 改动库结构/索引/物理文件都会使 EX 不可比, 故一律保持原样。

三、Baseline

Baseline = O1: one-shot $\times$ 1 (T=0, 无工具) ——最朴素的 LLM 方案, 也是”是否值得引入额外复杂度”的判据。预实验 (500 题全量预跑) 测得基线量级 O1 EX $\approx$ 57.8%, 与官方 Mini-Dev 参考基线同量级 (gpt-4 47.8、TA+gpt-4-turbo 58.0、TA+gpt-4o 63.0), 可作对照起点。

主指标	EX: <code>set(pred) == set(gold)</code> , 复用官方 <code>execute_sql + calculate_ex</code> , 与榜单口径一致
辅助指标	列级召回、幻觉率 (sqlglot 解析); 执行异常分 <code>exec_error / timeout</code>
成本指标	每题调用次数、输入/输出 token、端到端延迟 P50/P95、SQL 执行耗时 QET
判据	同一批题逐题配对做 McNemar 精确检验; 重跑噪声底约 $\pm 1pt$, 故要求提升 $\geq 3pt$ 且 $p < 0.05$ 方认定有效

四、采用的方法 (Method)

三组对照, 同一冻结模型、同一批题、同一批次运行, 唯一自变量是”如何产生并筛选 SQL”。

组	方法	温度	工具 / 关键实现
O1	one-shot $\times$ 1 (Baseline)	0.0	无工具
O3	采样 $\times$ 3 + 按执行结果集哈希聚类投票	0.7	候选各自执行, 按结果集哈希取多数簇
A1	agent 循环 + 输出形态自检	0.0	run_sql 回灌、submit_answer 终止

A1 的具体机制 (预期的主要增益来源)

- 输出形态自检: prompt 第一步先定”问题要哪几列”再写 SQL; run_sql 回报”N 行 / M 列 (列名...) + 3 行预览”, 让模型对照形态而非靠猜。
- 受控执行沙箱: 返回行数上限 100、单条 SQL 超时 5s、回灌截断 2000 字符, 避免大结果集拖垮上下文。
- 终止动作: submit_answer 提交即停、提交物须可执行; max_steps=10 仅作安全护栏, 不是实验变量。

待验证假设. H1: A1 相对 O1 显著提升, 预期 +5~7pt (63%~65%)。H2: 增益来自具体机制而非”多轮”本身——改动前约 48.6% 的错题是列数不匹配, 若该比例在 A1 上明显下降则因果链闭合 (相对 O1 只增加”输出形态自检”这一个自变量)。H3: 若多数题上三个候选的结果集完全相同, 投票即空操作, 预期最多约 25% 的题存在真实分歧, O3 收益有限。

评测与产出. 跑组落盘 results/<group>.jsonl, 判分复用官方脚本产出 <group>_scored.jsonl 与 EX@k; 配对与分层分析按难度、gold 所需表数、EXPLAIN 访问路径三维度展开。

预算与风险. 全量 500 题成本约 O1 ¥0.4 / O3 ¥1.2 / A1 ¥5.3, 合计约 ¥7; 对策: 循环不收敛 $\rightarrow$ submit_answer 强制终止并兜底最后一条可执行 SQL; 断点续跑漏题 $\rightarrow$ 以 qidx 作键。